

Operator Learning-Based Scalable Inverse Design for Multi-Zone Wafer Thermal Processing

Younghwan Kim¹ and Taejin Kim^{1,2}

¹ Department of Mechanical and Aerospace Engineering, Seoul National University, Seoul 08826, Republic of Korea

² Department of Industrial and Information Systems Engineering, Jeonbuk National University, Jeonju, 54896, Republic of Korea

³ OnePredict Inc., Seoul 08826, Republic of Korea

Abstract – 급속 열처리(Rapid Thermal Processing, RTP)는 반도체 제조 공정에서 웨이퍼 온도 균일성과 열 예산(Thermal Budget)을 정밀하게 제어해야 하는 핵심 열공정이다. 그러나 다중 존(Multi-zone) RTP 시스템에서는 복사 열전달에 의해 강한 비선형 열 간섭이 발생하며, 가열 존 수가 증가함에 따라 제어 및 최적화 문제가 고차원화되는 특성이 있다. 이러한 이유로 기존의 모델 기반 최적화나 강화학습(Reinforcement Learning) 기반 접근은 계산 비용 증가와 확장성 측면에서 한계가 있다. 본 연구에서는 이러한 문제를 해결하기 위해 연산자 학습(Operator Learning) 기반의 확장 가능한 역설계 프레임워크를 제안한다. 제안된 방법은 Deep Operator Network (DeepONet)를 이용하여 다중 램프 입력과 웨이퍼 온도 분포 사이의 비선형 매핑을 학습한다. 학습된 연산자의 미분 가능성을 활용하여 목표 온도 분포를 만족하는 램프 파워 프로파일을 경사 기반 최적화 방식으로 계산한다. 기존 최적화 기반 접근이 장비 구성마다 별도의 최적화를 요구하는 것과 달리, 제안된 방법은 단일 학습된 연산자를 통해 다양한 존 구성에 대해 확장 가능한 역설계를 수행할 수 있다. 수치 실험 결과, 제안된 프레임워크는 가열 존 수와 무관하게 약 16.9초 이내에 물리적 제약을 만족하는 공정 레시피를 생성할 수 있었다. 특히 열 간섭이 강한 10-Zone RTP 환경에서도 웨이퍼 전면의 온도 편차를 약 1.16 K 수준으로 유지하였다. 또한 다중 램프 결함 상황에서도 가용 에너지를 재분배하여 안정적인 온도 제어 성능을 유지하는 특성을 보였다. 이러한 결과는 연산자 학습이 다중 존 RTP 시스템의 역설계 문제를 효율적으로 해결할 수 있음을 보여주며, 향후 반도체 열공정 제어 및 디지털 트윈 기반 공정 최적화에 활용될 수 있음을 시사한다.

Keywords – Rapid Thermal Processing (RTP), Deep Operator Network (DeepONet), Operator Learning, Inverse Design, Thermal Process Control, Multi-Zone Thermal Systems

1 Introduction

급속 열처리(Rapid Thermal Processing, RTP)는 도펀트 활성화, 산화, 어닐링과 같은 다양한 반도체 열처리 공정에 널리 사용되는 핵심 기술이다. 기존의 배치(batch) 방식 열처리 장비와 달리 RTP

¹ Ph.D. Graduate, email@here

² Assistant Professor, tjkim@jbnu.ac.kr, Corresponding Author, Tel: +863 744270 4272.

시스템은 매우 빠른 승온 및 냉각 속도를 제공하여 웨이퍼에 적용되는 열 예산(Thermal Budget)을 정밀하게 제어할 수 있다. 이를 통해 불필요한 도펀트 확산을 최소화하면서 필요한 열처리 효과를 달성할 수 있다 [24,31]. 이러한 특성으로 인해 RTP 공정은 현대 반도체 제조에서 중요한 역할을 수행하고 있으며, 특히 SiC 와 같은 와이드밴드갭(Wide Bandgap) 소재의 고온 열처리 공정 연구에도 활발히 적용되고 있다 [10]. 따라서 RTP 시스템에서 웨이퍼 온도 분포를 정밀하게 제어하는 문제는 반도체 공정 제어 및 제조 자동화 분야에서 오랫동안 중요한 연구 주제로 다루어져 왔다 [30,31,34].

RTP 시스템의 온도 제어는 공정 특성상 여러 가지 기술적 어려움을 동반한다. RTP 공정에서는 복사(Radiation) 열전달이 지배적이며, 이로 인해 강한 비선형 열 동역학이 발생한다. 또한 웨이퍼 온도는 공간적으로 분포된 분포형(distributed) 시스템의 특성을 가지므로 웨이퍼 전체 영역에 걸쳐 온도를 균일하게 유지하는 것이 중요한 과제가 된다 [27,31]. 특히 대구경 웨이퍼 공정에서는 웨이퍼 중심부와 가장자리 사이의 열 손실 차이를 보정하기 위해 다중 램프 기반의 다중 존(Multi-zone) 가열 구조가 사용되며, 이로 인해 가열 존 간 강한 열 간섭(thermal coupling)이 발생한다 [15,33]. 이러한 구조적 특성은 웨이퍼 전면의 온도 균일도 유지 문제를 더욱 복잡하게 만들며, 이는 공정 품질과 소자 특성에 직접적인 영향을 미친다 [7,15]. 또한 웨이퍼 온도는 일반적으로 파이로미터와 같은 비접촉 광학 센서를 통해 측정되는데, 이러한 센서는 공간 해상도 및 측정 환경 측면에서 여러 제약을 가진다 [8,10,15]. 이에 따라 제한된 센서 정보를 이용하여 웨이퍼 온도 분포를 추정하거나 최적 측정 위치를 결정하는 문제 역시 RTP 연구에서 중요한 주제로 다루어져 왔다 [13-16,18,32].

이러한 문제를 해결하기 위해 다양한 RTP 제어 기법이 제안되어 왔다. 초기 연구에서는 RTP 시스템의 열 동역학 모델링과 다중 존 가열 구조를 고려한 분산 제어 전략과 같은 물리 기반 모델 제어 접근이 주를 이루었다 [34]. 이후 반복 학습 제어(Iterative Learning Control, ILC) 및 초기 학습 기반(learning-based) 접근 [25,26,28,29], 슬라이딩 모드 제어(SMC) [21], 최적 제어 기반 접근 [20] 및 모델 예측 제어(Model Predictive Control, MPC) [24] 등 다양한 고급 제어 기법이 적용되어 웨이퍼 온도 균일도와 공정 안정성을 향상시키는 연구가 수행되었다. 또한 제한된 센서 측정만으로 웨이퍼 온도 분포를 추정하기 위해 관측기(observer) 기반 접근을 비롯하여[13-16,18], SINDy 를 활용한 희소 동역학 식별이나 헬륨 압력을 활용한 상태 추정 등 다양한 방법론이 활발히 연구되었다 [9,11]. 그러나 이러한 방법들은 대부분 정확한 시스템 모델에 의존하거나 특정 장비 구조에 맞추어 설계되기 때문에 장비 구성이나 공정 조건이 변화할 경우 추가적인 비선형 모델 식별 [23]과 제어기 재설계가 필요하다는 한계를 가진다 [19,20,23,24].

한편 RTP 제어 문제를 단순한 온도 궤적 추종 문제로만 접근하는 대신, 공정에서 요구되는 열 예산을 직접 만족하도록 공정 레시피를 설계하는 접근도 제안되었다. 예를 들어 Jeng 과 Chen 은 스파이크(spike) RTP 공정에서 열 예산 지표를 직접 제어 목표로 설정하고, 목표 온도 프로파일의 최대 온도와 승온 및 냉각 속도 등의 파라미터를 최적화하거나 설정점 프로파일(set-point profile)을 재설계하여 원하는 열 예산을 달성하는 제어 전략을 제안하였다 [22]. 이 연구는 온도 궤적을 추종하는 방식 대신 열 예산 지표 자체를 설계 대상으로 설정함으로써 RTP 공정을 공정 레시피 설계 관점에서 접근할 수 있음을 보여준다.

최근에는 RTP 시스템의 복잡한 동역학을 다루기 위해 학습 기반 접근도 시도되고 있다. 특히 강화학습(Reinforcement Learning)을 이용하여 다중 존 RTP 시스템의 제어 정책을 학습하는 방법이

제안되었다 [17]. 그러나 기존 연구에 따르면 비교적 단순한 3-zone RTP 시스템에서도 최적 제어 정책을 학습하는 데 약 96,056 초 이상의 계산 시간이 필요하며, 이는 가열 존 수가 증가할수록 계산 비용이 급격히 증가하는 차원의 저주(Curse of Dimensionality) 문제를 보여준다. 이러한 계산 복잡도 문제는 실제 공정에서 사용되는 다수의 가열 존을 가지는 RTP 시스템에 대해 기존 최적화 기반 접근의 확장성을 제한하는 요인이 된다.

한편 최근 머신러닝 분야에서는 편미분방정식(PDE) 기반 물리 시스템을 직접 학습하는 연산자 학습(Operator Learning) 방법론이 제안되고 있다. Deep Operator Network(DeepONet)는 함수 공간 간 비선형 연산자를 근사할 수 있는 신경망 구조로, 다양한 PDE 기반 물리 시스템 모델링 문제에서 효과적인 근사 모델로 활용되고 있다 [1]. 이후 이러한 신경 연산자는 열전도 문제와 같은 물리 기반 시스템 모델링 [2], 형상 최적화와 같은 PDE 제약 최적화 문제 [3,4] 등으로 적용 범위가 확장되고 있으며, 최근에는 목표 상태에서부터 제어 입력을 직접 추정하는 역연산자(inverse operator) 학습 접근도 제안되고 있다 [5,6]. 이러한 연구들은 연산자 학습이 복잡한 물리 시스템의 모델링과 역문제 해결에 효과적인 방법이 될 수 있음을 시사한다.

이러한 배경을 바탕으로 본 연구에서는 다중 존 RTP 시스템의 공정 레시피 설계 문제를 해결하기 위한 연산자 학습 기반 역설계(inverse design) 프레임워크를 제안한다. 제안된 방법은 Deep Operator Network 를 이용하여 다중 램프 입력과 웨이퍼 온도 분포 사이의 비선형 매핑을 학습하고, 학습된 연산자의 미분 가능성을 활용하여 목표 온도 분포를 만족하는 램프 파워 프로파일을 gradient 기반 최적화를 통해 계산한다. 또한 다양한 장비 구성을 단일 신경 연산자 모델에서 처리할 수 있도록 구성 적응형(configuration-adaptive) 입력 구조를 도입하여 서로 다른 가열 존 수를 가지는 RTP 시스템에 대해 통합적인 역설계가 가능하도록 하였다. 이를 통해 기존 최적화 또는 강화학습 기반 접근에서 발생하는 계산 비용 문제를 완화하면서 다양한 존 구성을 갖는 RTP 시스템에 대해 확장 가능한 공정 레시피 설계가 가능함을 보였다. 또한 다중 램프 결함 상황에서도 에너지 재분배를 통해 안정적인 온도 분포를 유지할 수 있음을 확인하여 제안된 방법이 결함 허용(fault-tolerant) 열공정 설계 프레임워크로 활용될 수 있음을 보였다.

2 Rapid Thermal Processing

2.1 System Description

급속 열처리(Rapid Thermal Processing, RTP)는 웨이퍼를 수 초 이내에 고온으로 승온 및 냉각시키는 공정이다. 이는 도펀트 활성화(Dopant Activation), 산화(Oxidation), 실리사이드 형성(Silicidation) 등 반도체 제조의 핵심 단계에 광범위하게 적용된다. 성공적인 공정을 위해서는 웨이퍼 전체의 온도를 정밀하게 제어하는 것이 필수적이다. 특히 웨이퍼의 직경이 300mm 이상으로 대형화됨에 따라 전면의 온도 균일성(Uniformity) 확보가 더욱 중요해졌으며, 이를 위해 동심원 형태의 다중 램프(Multi-zone) 구조가 도입되었다. Figure 1 에 이러한 구조를 보였다. Figure 1(a)의 상단 투영도(Top view)와 Figure 1(b)의 측면 단면도(Side view)에 나타난 바와 같이, 본 연구에서 다루는 RTP 시스템은 크게 가열부(Lamp heating module), 석영 창(Quartz window), 반응 챔버(Reaction chamber), 그리고 온도 계측부(Temperature measurement unit)로 구성된다.

가열부는 주 열원인 텅스텐-할로겐 램프(Tungsten-Halogen Lamp) 어레이와 복사 효율을 극대화하기 위한 반사판(Reflector)으로 이루어져 있다. 특히, 웨이퍼 중심부부터 가장자리까지 반경 방향(Radial direction)의 열 유속(Heat flux)을 독립적으로 제어하기 위해, 가열부는 Figure 1(a)와 같이

동심원 형태의 10 개 가열 존(Zone 1-10)으로 분할되어 있다. 중심부(Zone 1)에서 외곽(Zone 10)으로 갈수록 독립적인 제어 구역을 세밀하게 배치한 이 다중 존(Multi-zone) 구조는, 대구경 웨이퍼의 가장자리(Edge)에서 상대적으로 크게 발생하는 복사 및 대류 열 손실(Heat loss)을 공간적으로 보상하여 전면의 온도 균일성을 확보하는 핵심적인 역할을 수행한다.

램프에서 방사된 복사 에너지는 열적, 화학적 차폐막 역할을 하는 두꺼운 석영 창을 통과하여 챔버 내부의 실리콘 웨이퍼(Silicon wafer)를 가열한다. 웨이퍼는 가장자리 열 손실을 완화하기 위한 엣지 링(Edge ring) 구조의 서셉터(Susceptor) 위에 안착되며, 공정 중 방위각 방향(Azimuthal direction)의 열적 대칭성을 확보하기 위해 일정한 속도로 회전(Rotation)한다.

마지막으로 챔버 하단에는 웨이퍼의 반경별 온도를 실시간으로 측정하기 위한 다중 파이로미터(Pyrometers)가 배치되어 있다. 각 파이로미터는 특정 가열 존에 대응하는 웨이퍼 하부 지점의 복사 에너지를 감지하며, 이를 통해 수집된 공간적 온도 분포 데이터는 다변수(Multivariable) 피드백 제어 및 본 연구에서 제안하는 역설계 프레임워크의 기준 데이터로 활용된다.




Fig. 1 Schematic diagram of the Rapid Thermal Processing (RTP) system: (a) top view of the multi-zone lamp array and (b) side view of the RTP chamber

2.2 RTP Modeling

본 연구는 다중 램프(Multi-zone) RTP 시스템의 비선형 열역학적 거동을 모사하기 위해, 선행 연구 [17,22,32]에서 사용된 복사 지배적 집중 모델(radiation-dominant lumped model)을 기반으로

한다. 본 모델에서는 웨이퍼가 매우 얇고 열전도율이 높으며, 반경 방향 온도 구배가 상대적으로 작다고 가정하여, 반경 방향 열전도 항은 복사 및 대류 항에 비해 무시할 수 있는 것으로 근사한다. 이에 따라 웨이퍼를 n 개의 동심원 링(Annular ring)으로 이산화했을 때, i 번째 링($i = 1, \dots, n$)에 대한 지배 방정식(ODE)은 다음과 같이 기술된다.

$$\begin{aligned} \rho C_p d \frac{dT_i}{dt} &= q_i^{\text{conv}} + q_i^{\text{rad}} + q_i^{\text{lamp}} \\ &= \sum_{j=1}^m \phi_{ij} P_j - \sigma \left(\sum_{j=1}^m \phi_{ij} \right) T_i^4 - h_c (T_i - T_a) \end{aligned}$$

여기서 T_i 는 i 번째 웨이퍼 링의 온도, P_j 는 j 번째 램프 존의 입력 전력, m 은 램프 존의 개수이다. σ 는 슈테판-볼츠만 상수, h_c 는 대류 열전달 계수, T_a 는 챔버 내부의 냉각 가스(Ambient) 온도이다. 웨이퍼의 물성치인 밀도(ρ), 두께(d), 그리고 비열(C_p)은 공정의 핵심 변수이며, 특히 비열 $C_p(T)$ 는 온도의 함수로 정의되어 비선형성을 반영한다. 본 연구의 열역학적 모델링에 적용된 구체적인 물리적 파라미터 값은 Table 1에 정리되어 있다.

위 식의 핵심 파라미터인 ϕ_{ij} 는 유효 열전달 계수(Effective Transfer Coefficient)로, 램프와 웨이퍼 간의 기하학적 뷰 팩터(F_{ij})와 웨이퍼 표면의 방사율(ϵ)을 결합하여 다음과 같이 정의된다.

$$\phi_{ij} = \frac{1}{(1 - \epsilon)/\epsilon + 1/F_{ij}}$$

여기서 F_{ij} 는 j 번째 램프 존에서 방출된 에너지가 i 번째 웨이퍼 링에 도달하는 기하학적 비율(View Factor)을 의미하며, 램프를 원환형 면적 광원(Annular area source)으로 고려하여 다음의 이중 적분식으로 계산된다.

$$F_{ij} = \frac{1}{\pi} \int_{r_{L,j-1}}^{r_{L,j}} \int_0^{2\pi} \frac{H^2}{S_{ij}^4} r_L d\theta_{ij} dr_L$$

이때 S_{ij} 는 웨이퍼의 i 번째 링과 램프의 미소 면적 간의 기하학적 거리로 다음과 같이 계산된다.

$$S_{ij}^2 = H^2 + r_{w,i}^2 + r_L^2 - 2r_{w,i}r_L \cos \theta_{ij}$$

여기서 H 는 램프와 웨이퍼 간 수직 거리, $r_{w,i}$ 는 웨이퍼 i 번째 링의 반지름, r_L 은 램프의 반경 변수이다. 계산된 유효 열전달 계수 ϕ_{ij} 는 챔버 내부의 복사 손실을 반영하기 위해 반사판 반사율을 고려한 스케일링(scaling) 계수를 적용하였다. 실제 RTP 챔버에서는 이상적인 닫힌계(Closed system)와 달리 반사판 등에서 복사 에너지의 일부가 흡수 및 손실된다. 이를 반영하기 위해, 본 연구에서는 선행 연구(Huang et al., 2000)에서 제시된 챔버 반사판의 반사율(Reflector reflectivity, $R = 0.97$)을 고려하여 유효 전달 계수에 스케일링 계수를 적용하였다. 또한 웨이퍼 가장자리에서 증가하는 복사 및 대류 열 손실(edge heat loss)을 반영하기 위해, 최외곽 웨이퍼 링에 대해 추가적인 복사 및 대류 손실 항을 고려하였다.

램프 존(Lamp Zone)의 물리적 구획은 제어 자유도(Degrees of Freedom)에 따라 전략적으로 설계되었다. 1-Zone부터 3-Zone까지는 벤치마크 연구(Jeng & Chen, 2013; Pradeep & Noel, 2018)와의 직접 비교를 위해 선행 연구에서 사용된 기존 램프 구획 방식을 그대로 유지하였다. 반면, 4-Zone 이상의 다변수 고해상도 제어 환경에서는 각 액추에이터의 에너지 밀도를 균일하게 유지하고, 가

장자리에서 발생하는 열손실을 효과적으로 보상하기 위해 등면적 분할 기법(Equal-area spatial division)을 적용하였다. 즉, 각 램프 존의 면적이 동일하도록 전체 램프 반경 r_L 에 대해 각 구역의 반경을 $r_{L,j} = r_L \sqrt{j/m}$ 로 설정하여, 바깥쪽 존으로 갈수록 램프가 조밀하게 배치되도록 설계하였다. 이를 통해 하드웨어의 물리적 특성을 모델에 반영하였으며, 다중 존 RTP 시스템 제어를 위한 물리적 타당성을 확보하였다.

Table 2. Physical Parameters for RTP Simulation

Parameter	Symbol	Value	Unit
Wafer density	ρ	2330	kg/m ³
Wafer Thickness	d	6.75×10^{-4} (0.0675 cm)	m
Specific heat capacity	$C_p(T)$	$641 + 0.2473 \cdot T$	J/(kg · K)
Emissivity	ϵ	0.7	-
Wafer radius	r_w	0.15 (15 cm)	m
Lamp radius	r_L	0.30 (30 cm)	m
Lamp-Wafer distance	H	0.05 (5 cm)	m
Stefan-Boltzmann constant	σ	5.67×10^{-8}	W/(m ² · K ⁴)
Convective heat coefficient	H_c	8.5	W/(m ² · K)
Ambient temperature	T_a	300.15(27 °C)	K
Reflector reflectivity	R	0.97	-

2.3 Generation of Input Function Space

DeepONet의 일반화 성능(generalization capability)은 학습 과정에서 사용되는 입력 함수 공간(input function space)의 다양성과 표현 범위에 크게 의존한다. 모델이 특정 온도 프로파일에 과적합되지 않고 RTP 공정의 전반적인 동적 특성을 학습할 수 있도록, 본 연구에서는 Figure 2에 나타난 바와 같이 다양한 유형의 기초 입력 신호(primitives)를 조합하여 램프 전력 입력 $u(t)$ 를 생성하였다. 각 램프 존의 전력 프로파일은 서로 독립적으로 생성되며, 이를 통해 다중 열원 간의 비선형 열 간섭(thermal coupling) 특성이 데이터셋에 자연스럽게 반영되도록 하였다.

먼저, Chebyshev 다항식을 기반으로 한 orthogonal polynomial trajectories를 이용하여 부드러운 연속 입력 신호를 생성하였다(Fig. 2a). 이러한 신호는 점진적인 승온 및 냉각 거동을 모사하는 데 사용

된다. 또한 시스템의 과도 응답 특성을 학습하기 위해 step 신호, square pulse 신호, 그리고 bang-bang 형태의 급격한 입력 변화를 포함한 transient excitation 신호를 생성하였다(Fig. 2b–2d). 이러한 신호들은 시스템의 시정수(time constant)와 동적 응답 특성을 학습하는 데 중요한 역할을 한다.

한편 실제 반도체 공정에서 사용되는 레시피 특성을 반영하기 위해 spike 및 soak 형태의 반도체 열처리 공정에서 널리 사용되는 산업 표준 공정 프로파일도 포함하였다(Fig. 2e). 이러한 입력은 실제 공정 환경에서 요구되는 온도 상승 및 유지 동작을 모사한다. 또한 시스템의 주파수 응답 특성을 학습하기 위해 다양한 주파수와 위상을 갖는 sinusoidal excitation 신호를 생성하였다(Fig. 2f). 이러한 harmonic probing 신호는 시스템의 동적 대역폭(dynamic bandwidth)과 주파수 응답 특성을 효과적으로 탐색하는 역할을 한다.

추가적으로 모델의 범용성을 확보하기 위해 초기 온도 T_0 , 웨이퍼 방사율 ϵ , 그리고 대류 열전달 계수 h_c 에 대해 파라미터 랜덤화(parameter randomization)를 적용하여 장비 및 공정 조건의 변화가 데이터셋에 반영되도록 하였다. 이러한 방식으로 다양한 장비 구성(1–10 zones)에 대해 충분한 학습 샘플을 생성하여 대규모 학습 데이터셋을 구축하였다. 이러한 데이터 생성 전략은 RTP 시스템의 다양한 동적 거동을 데이터셋에 반영하며, 학습된 모델이 학습 과정에서 등장하지 않은 온도 경로에 대해서도 일반화된 역설계 성능을 갖도록 한다.




Fig. 2 Representative power profile primitives used for training data generation: (a) orthogonal polynomials, (b) random step signals, (c) square pulse (max-to-zero), (d) bang-bang control signals, (e) industrial spike/soak profiles, and (f) sinusoidal excitation signals.

3 DeepONet-based Forward Model

3.1 DeepONet architecture for RTP forward model

연산자 학습(Operator Learning)은 유한 차원의 벡터 공간 간 매핑이 아닌 함수 공간(Function Space) 간 매핑을 직접 근사하는 접근 방법이다. 대표적인 연산자 학습 모델인 Deep Operator Network(DeepONet)는 입력 함수를 처리하는 Branch Net 과 시공간 좌표를 처리하는 Trunk Net 으로 구성되며, 두 네트워크 출력의 내적을 통해 연산자를 근사한다. 이러한 구조는 편미분방정식(PDE)로 기술되는 물리 시스템의 대리 모델(Surrogate Model) 구축에 활용되고 있다. Figure 3 은 본 연구에서 사용한 DeepONet 기반 RTP 순방향 모델 구조를 나타낸다.

본 연구에서는 램프 존 수가 서로 다른 RTP 시스템(1–10 Zones)을 단일 네트워크로 처리하기 위해 구성 적응형 인코딩(Configuration-adaptive Encoding)을 도입하였다. 입력 함수 공간을 정의하는 입력 벡터는 다음과 같이 정의된다.

$$u_{\text{unified}}(t) = [P_{\text{pad}}(t), T_0, c_{\text{zone}}]$$

여기서 $P_{\text{pad}}(t)$ 는 제로 패딩을 적용한 램프 전력 벡터이다. 시스템의 최대 램프 개수인 $N_{\text{max}} = 10$ 에 맞추어, 램프 존 수가 n 인 경우 입력 전력은 다음과 같이 표현된다.

$$P_{\text{pad}}(t) = [P_1(t), \dots, P_n(t), 0, \dots, 0]$$

이를 통해 서로 다른 램프 존 구성을 갖는 RTP 시스템에 대해 입력 차원을 일정하게 유지할 수 있다.

공정 시작 온도 T_0 는 Z-score 정규화를 통해 다음과 같이 변환된다.

$$T_{0,\text{norm}} = \frac{T_0 - \mu_T}{\sigma_T}$$

여기서 μ_T 와 σ_T 는 각각 학습 데이터에서의 초기 온도 분포의 평균과 표준편차를 의미한다.

또한 현재 장비의 램프 구성을 표현하기 위해 정규화된 존 식별자를 다음과 같이 정의하였다.

$$c_{\text{zone}} = \frac{n}{N_{\text{max}}}$$

이 인코딩을 통해 동일한 입력값이 0 이 실제 제어 입력이 없는 경우인지, 또는 해당 존이 물리적으로 존재하지 않는 경우인지를 모델이 구분할 수 있다. 이러한 입력 구조를 통해 단일 모델이 서로 다른 램프 구성의 RTP 시스템을 처리할 수 있다.

Branch Net 은 12 차원의 시계열 입력 $u_{\text{unified}}(t)$ 의 시간적 종속성(Temporal Dependency)을 표현하기 위해 3 층의 양방향 LSTM(Bi-directional LSTM) 구조를 사용한다. 각 시간 스텝 t 에서의 은닉 상태는 다음과 같이 계산된다.

$$\begin{aligned} h_t^{(f)} &= \text{LSTM}_{\text{forward}}(u_{\text{unified}}(t), h_{t-1}^{(f)}) \\ h_t^{(b)} &= \text{LSTM}_{\text{backward}}(u_{\text{unified}}(t), h_{t+1}^{(b)}) \end{aligned}$$

두 방향의 은닉 상태는 다음과 같이 결합된다.

$$h_t = [h_t^{(f)} \oplus h_t^{(b)}]$$

최종 시점의 은닉 상태 h_{last} 는 다층 퍼셉트론(MLP)으로 전달되어 branch feature 벡터를 생성한다.

$$b = \phi_{\text{MLP}}(h_{\text{last}})$$

이때 MLP는 SiLU(Sigmoid Linear Unit) 활성화 함수를 포함한 선형 계층들로 구성되며, 최종적으로 128 차원의 잠재 벡터 b 를 출력한다.

Trunk Net 은 시공간 좌표 (t, r) 을 입력으로 받아 기저 함수(Basis function)을 생성한다. 여기서 r 은 앞서 정의한 웨이퍼의 15 개 동심원 링의 중심 좌표를 의미한다. Trunk Net 은 잔차 연결(residual connection)이 포함된 fully connected block 으로 구성되며 각 블록의 연산은 다음과 같이 표현된다.

$$z_{l+1} = z_l + \tanh(\mathcal{F}(z_l; \theta_l))$$

여기서 $\mathcal{F}$ 는 해당 블록 내의 비선형 잔차 매핑(Residual mapping) 함수를 의미하며, θ_i 은 학습 가능한 가중치 및 편향 파라미터이다. 활성화 함수로는 tanh를 사용하였고, 두 네트워크 출력의 내적(Dot Product)과 편향(Bias) 항의 합을 통해 연산자 출력이 계산된다.

$$\hat{G}(u)(t, r) = \sum_{i=1}^{128} b_i t_i(t, r) + \beta$$

데이터 기반 모델의 물리적 일관성을 유지하기 위해 초기 조건을 만족하도록 구조적 제약을 적용하였다. 최종 온도 예측은 다음과 같이 정의된다.

$$\hat{T}(t, r) = T_{0, input} + t \cdot \hat{G}(u)(t, r)$$

여기서 $T_{0, input}$ 은 입력 벡터 $u_{unified}$ 의 11 번째 채널에서 추출된 값이며 $t \in [0, 1]$ 이다. 이 구조는 다음 조건을 항상 만족한다.

$$\hat{T}(0, r) = T_{0, input}$$

학습 손실 함수는 온도 재구성 오차와 시간 변화율 오차의 합으로 정의된다.

$$L_{total} = L_{MSE} + L_{grad}$$

온도 오차는 다음과 같다.

$$L_{MSE} = \frac{1}{N_t N_r} \sum_{i=1}^{N_t} \sum_{j=1}^{N_r} (\hat{T}(t_i, r_j) - T(t_i, r_j))^2$$

또한 시간 변화율을 반영하기 위해 gradient loss를 추가하였다.

$$L_{grad} = \frac{1}{(N_t - 1) N_r} \sum_{i=1}^{N_t-1} \sum_{j=1}^{N_r} \left(\frac{\Delta \hat{T}(t_i, r_j)}{\Delta t} - \frac{\Delta T(t_i, r_j)}{\Delta t} \right)^2$$

여기서 Δt 는 인접한 시간 스텝 간 간격을 의미한다. L_{grad} 항은 온도 값뿐 아니라 공정의 시간적 변화 특성을 함께 학습하도록 한다.




Fig. 3 DeepONet architecture used for the RTP forward model.

3.2 Model Training and Validation

DeepONet 모델의 학습은 구축된 데이터셋을 8:2 비율로 학습(Training) 및 검증(Validation) 세트로 분할하여 수행하였다. 최적화 알고리즘으로는 Adam Optimizer를 사용하였으며, 학습률(Learning Rate)은 초기 10^{-3} 에서 시작하여 검증 손실(Validation Loss)이 개선되지 않을 때마다 감소시키는 적응형 스케줄링을 적용하였다.

Table 2 는 서로 다른 램프 존 구성(1-10 zones)에 대해 평가된 모델의 예측 오차를 나타낸다. 각 구성에 대한 성능 평가는 테스트 데이터셋에서 계산된 평균 제곱 오차(mean squared error, MSE)를 기준으로 수행하였다. 평가 결과, 1-Zone 부터 10-Zone 까지 모든 존 구성에서 예측 오차는 약 $0.08 \sim 0.13 K^2$ 범위 내에 분포하였다.

Figure 4 는 10-Zone RTP 시스템에서의 입력 전력 프로파일과 이에 대한 온도 예측 결과를 나타낸다. 그림 (a)는 10 개의 램프 존에 대해 생성된 입력 전력 프로파일을 보여주며, 그림 (b)는 웨이퍼 중심, 중간 반경, 가장자리 위치에서의 온도 예측 결과를 나타낸다. 예측된 온도 분포는 기준 열 모델(lumped parameter model)로부터 계산된 결과와 비교하여 제시하였다.

이 결과는 학습된 모델이 다양한 램프 존 구성에서 입력 전력과 웨이퍼 온도 분포 사이의 매핑을 재현할 수 있음을 보여준다.

Table 2. Prediction Error of the Forward Model for Different Zone Configurations (Metric : Mean Squared Error on Test Dataset)

Zone Config.	MSE (K^2)	Zone Config.	MSE (K^2)
1-Zone	0.1107	6-Zone	0.0907
2-Zone	0.0871	7-Zone	0.0945
3-Zone	0.0950	8-Zone	0.0992
4-Zone	0.0892	9-Zone	0.1084
5-Zone	0.0864	10-Zone	0.1296




Fig. 4 Forward Model Prediction for a 10-Zone RTP System: (a) Input power trajectories for 10 lamp zones, (b) Temperature prediction compared with the lumped thermal model

4 Inverse Design for Temperature Profile Generation

본 장에서는 앞서 구축한 DeepONet 기반 forward model 을 이용하여 RTP 공정에서 목표 온도 프로파일을 만족하는 램프 전력 입력을 계산하는 역설계(inverse design) 프레임워크를 정의한다.

제어 입력은 웨이퍼 온도 추종 정확도와 공간적 온도 균일성을 동시에 고려하는 목적 함수의 최소화를 통해 계산된다. 제안된 프레임워크는 목표 온도 프로파일 $T_{\text{target}}(t)$ 이 주어졌을 때 이를 만족하는 램프 전력 프로파일 $u^*(t)$ 를 사전에 최적화하는 것을 목표로 한다.

4.1 Inverse Design Framework

4.1.1 Objective Function Design

역설계 문제는 다음과 같은 최적화 문제로 정의한다.

$$\mathbf{u}^* = \arg \min_{\mathbf{u}} \mathcal{L}_{\text{total}}(\mathbf{u})$$

여기서 전체 목적 함수는 다음과 같이 정의된다.

$$\mathcal{L}_{\text{total}} = \lambda_{\text{perf}} \mathcal{L}_{\text{MSE}} + \lambda_{\text{unif}} \mathcal{L}_{\text{unif}} + \lambda_{\text{smooth}} \mathcal{L}_{\text{smooth}}$$

각 항은 온도 추종 정확도, 웨이퍼 온도 균일성, 그리고 제어 입력의 시간적 변화율을 반영한다.

온도 추종 오차는 웨이퍼 반경 방향 전체 영역과 공정 시간 구간에 대해 정의된다.

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N_t N_r} \sum_{i=1}^{N_t} \sum_{j=1}^{N_r} (\hat{T}(t_i, r_j) - T_{\text{target}}(t_i))^2$$

여기서 N_t 는 시간 샘플 수이며 N_r 은 웨이퍼 반경 방향 샘플 수이다.

웨이퍼 내 공간적 온도 균일성을 고려하기 위해 각 시간 스텝에서의 최대 온도와 최소 온도 차이를 기반으로 uniformity loss 를 정의하였다.

$$\mathcal{L}_{\text{unif}} = \frac{1}{N_t} \sum_{i=1}^{N_t} \left(\max_{1 \leq j \leq N_r} \hat{T}(t_i, r_j) - \min_{1 \leq j \leq N_r} \hat{T}(t_i, r_j) \right)^2$$

이 항은 웨이퍼 반경 방향 온도 편차를 최소화하도록 제어 입력을 유도한다.

또한 실제 램프 구동 환경에서 적용 가능한 전력 프로파일을 생성하기 위해 제어 입력의 시간적 변화율을 제어하는 smoothness 항을 포함하였다.

$$\mathcal{L}_{\text{smooth}} = \frac{1}{(N_t - 1)K} \sum_{i=1}^{N_t-1} \sum_{k=1}^K (u_k(t_{i+1}) - u_k(t_i))^2$$

여기서 K 는 활성화된 램프 존의 개수를 의미한다. 이 항은 인접한 시간 스텝 간 램프 전력 변화가 과도하게 커지는 것을 방지하도록 한다.

4.1.2 Gradient-based Optimization Process

Forward model 로 사용된 DeepONet 은 입력에 대해 미분 가능(differentiable)하므로, 목적 함수 $\mathcal{L}_{\text{total}}(\mathbf{u})$ 를 입력 전력 프로파일 $u(t)$ 에 대해 직접 최소화할 수 있다. 본 연구에서는 제어 입력을 최적화하기 위해 Adam optimizer 기반의 경사 하강법(gradient-based optimization)을 사용하였다. DeepONet 의 네트워크 가중치는 고정된 상태에서의 입력 전력 $u(t)$ 를 최적화 변수로 설정하고, 자동 미분(automatic differentiation)을 통해 목적 함수의 기울기를 계산한다. 이러한 방식은 기존의 반복적인 열 모델 시뮬레이션 기반 탐색 방법과 달리, 미분 가능한 대리 모델을 이용하여 직접적으로 입력을 갱신할 수 있다.

각 반복 단계에서 입력 전력은 다음과 같이 갱신된다.

$$u^{k+1} = u^k - \eta \nabla_{\mathbf{u}} \mathcal{L}_{\text{total}}(u^k)$$

여기서 η 은 학습률이며 k 는 반복 인덱스를 나타낸다. 최적화 과정에서는 Adam optimizer 를 사용하여 모멘트 기반의 적응형 학습률 업데이트를 적용하였다. 또한 램프 전력의 물리적 제한 조건을 반영하기 위해 다음의 제약 조건을 고려하였다.

$$0 \leq u_k(t) \leq u_{\text{max}}$$

이 제약 조건은 각 반복 단계에서 projected gradient 방법을 적용하여 만족하도록 하였다. 즉, 매 반복 후 계산된 전력 값이 허용 범위를 벗어나는 경우 이를 허용 가능한 범위로 투영(projection)하였다.

미분 가능한 신경 연산자를 활용한 입력 최적화 방식은 최근 PDE 기반 설계 및 최적화 문제에서 널리 사용되고 있다 [3,4]. 본 연구에서는 이를 RTP 시스템의 공정 레시피 생성 문제에 적용하였다.

4.1.3 Evaluation Metrics

제안된 역설계 프레임워크의 성능을 평가하기 위해 온도 추종 정확도, 최대 온도 오차, 그리고 웨이퍼 온도 균일성을 나타내는 지표를 사용하였다.

온도 추종 정확도는 목표 온도 프로파일과 예측된 온도 사이의 평균 제곱 오차(mean squared error, MSE)로 정의된다.

$$MSE = \frac{1}{N_t N_r} \sum_{i=1}^{N_t} \sum_{j=1}^{N_r} \left(\hat{T}(t_i, r_j) - T_{\text{target}}(t_i) \right)^2$$

여기서 N_t 는 시간 샘플 수이며 N_r 은 웨이퍼 반경 방향 샘플 수이다.

공정의 열 예산 관리와 관련된 최대 온도 오차는 다음과 같이 정의된다.

$$e_{\text{peak}} = \max_{1 \leq i \leq N_t} |\hat{T}_{\text{edge}}(t_i) - T_{\text{target}}(t_i)|$$

또한 웨이퍼 전면의 온도 균일성을 평가하기 위해 반경 방향 온도 편차를 다음과 같이 정의하였다.

$$e_{\text{unif}} = \max_{1 \leq i \leq N_t} \left(\max_{1 \leq j \leq N_r} \hat{T}(t_i, r_j) - \min_{1 \leq j \leq N_r} \hat{T}(t_i, r_j) \right)$$

이 지표는 공정 시간 동안 발생하는 최대 온도 불균일도를 나타낸다.

4.2 Experimental Results and Discussion

4.2.1 Overall Performance and Scalability

제안된 역설계 프레임워크의 확장성(scalability)을 평가하기 위해 단일 모델을 사용하여 1-zone부터 10-zone 까지 다양한 장비 구성에 대해 성능을 비교하였다. Table 3 은 표준 스파이크(Standard Spike) 시나리오에서 각 존 구성에 대한 평균 제곱 오차(MSE), 최대 피크 오차(Peak Error), 웨이퍼 온도 균일도(Uniformity), 그리고 최적화 소요 시간(Optimization Time)을 정리한 것이다.

Table 3 에서 확인할 수 있듯이, 램프 존 수가 증가함에 따라 제어 변수의 수와 열 간섭(thermal coupling)의 복잡성이 증가함에도 불구하고 전체 온도 추종 오차는 유사한 범위를 유지하였다. 평균 제곱 오차는 1-Zone 에서 3.62 K^2 , 10-Zone 에서 3.63 K^2 수준으로 나타났으며, 중간 존 구성에서도 약 $3.6 \sim 4.9 \text{ K}^2$ 범위에 분포하였다. 또한 최대 피크 온도 오차는 모든 장비 구성에서 약 5.3 K 수준으로 관찰되었다.

공간적 온도 균일성 측면에서, 다중 존 제어가 가능한 2-zone 이상의 구성에서는 웨이퍼 전면의 온도 편차가 약 $0.8 \sim 1.3 \text{ K}$ 범위에 분포하였다. 특히 10-zone 구성에서도 약 1.16 K 수준의 균일도가 유지되었다. 이러한 결과는 존 수가 증가하더라도 제안된 역설계 방법이 반경 방향 온도 편차를 일정 범위 내에서 유지할 수 있음을 보여준다.

또한 Table 3 에 나타난 바와 같이 역설계 최적화에 소요되는 계산 시간은 존 구성에 관계없이 약 $16.8 \sim 16.9 \text{ s}$ 범위에서 유지되었다. 이는 최적화 과정이 미분 가능한 DeepONet forward model 을

기반으로 수행되기 때문에, 입력 변수 차원이 증가하더라도 반복 계산 비용이 크게 증가하지 않음을 보여준다.

Table 3. Inverse Design Performance across Different Zone Configurations (Case 1: Standard Spike)

Zone Config.	MSE (K^2)	Peak Error (K)	Uniformity (K)	Optimization Time (s)
1-Zone	3.6164	5.2730	1.0657	16.9
2-Zone	4.1485	5.3448	0.8391	16.8
3-Zone	3.9683	5.3789	0.8857	16.9
4-Zone	4.1875	5.3419	0.9202	16.9
5-Zone	4.9480	5.3083	0.8712	16.9
6-Zone	4.9251	5.3034	1.1895	16.9
7-Zone	4.6006	5.3086	1.3661	16.9
8-Zone	4.1409	5.3131	1.3154	16.8
9-Zone	3.7743	5.3230	1.1193	16.8
10-Zone	3.6338	5.3340	1.1606	16.9

4.2.2 Representative Process Scenarios

Table 4. Quantitative performance of the proposed inverse design method across six scenarios

Case Scenario	MSE (K^2)	Peak Error (K)	Uniformity (K)
Case 1 : Standard Spike	3.6338	5.3340	1.1606
Case 2 : Long Soak	0.6441	1.7041	1.0743
Case 3 : Soak to Spike	1.1986	3.9014	1.8081
Case 4 : Single Fault	2.1703	5.5265	2.4880
Case 5 : Double Fault	12.1485	8.5062	7.6151
Case 6 : Saturation Sine	55.8532	15.3237	3.2880


제안된 역설계 방법의 제어 거동을 보다 상세히 분석하기 위해 열 간섭이 가장 크게 나타나는 10-zone RTP 시스템을 대상으로 여러 대표적인 공정 시나리오를 구성하였다. Table 4 는 각 시나리오에 대해 평균 제곱 오차(MSE), 최대 피크 온도 오차(Peak Error), 그리고 웨이퍼 온도 균일도(Uniformity)를 정리한 것이다. 또한 Figure 6 은 일부 대표 시나리오에 대해 최적화된 램프 전력 프로파일과 이에 대응하는 온도 응답을 나타낸다.

Case 1 은 빠른 승온 이후 즉각적인 냉각이 요구되는 표준 스파이크 공정을 나타낸다. Figure 6(a)에서 확인할 수 있듯이 승온 구간에서는 대부분의 램프가 높은 전력 수준으로 구동되어 목표 온도에 빠르게 도달하며, 피크 이후에는 램프 출력이 급격히 감소하여 냉각이 시작된다. 또한 램프 출력이 반경 방향 위치에 따라 서로 다른 수준으로 분포하는 것을 확인할 수 있다. 특히 가장자리 램프의 출력이 중심부보다 상대적으로 높게 유지되는 경향이 나타나는데, 이는 RTP 챔버에서 가장자리 영역의 열 손실이 더 크게 발생하는 특성과 일관된 전력 분배 패턴으로 해석될 수 있다. Table 4 에 따르면 이 시나리오에서의 평균 제곱 오차는 $3.63 K^2$, 피크 오차는 약 5.33 K, 웨이퍼 온도 균일도는 약 1.16 K 수준으로 나타났다.

Case 2 는 목표 온도를 일정 시간 동안 유지하는 장기 유지(long soak) 시나리오이다. Figure 6(b)에서 나타난 것처럼 목표 온도에 접근하는 구간에서 일부 램프 출력이 일시적으로 감소하는 구간이 관찰된다. 이러한 전력 감소는 열 관성(thermal inertia)에 의해 발생할 수 있는 온도 오버슈트를

완화하기 위한 제어 동작으로 해석할 수 있다. 목표 온도에 도달한 이후에는 램프 출력이 비교적 안정적인 수준으로 유지되며, Table 4 에 따르면 평균 제곱 오차는 0.64 K^2 , 웨이퍼 온도 균일도는 약 1.07 K 수준으로 나타났다.

Case 3 은 유지 구간 이후 추가적인 승온이 발생하는 복합 과도 응답 시나리오이다. Figure 6(c)에서 확인할 수 있듯이 초기 유지 구간 이후 두 번째 승온 단계에서 램프 출력이 다시 증가한다. 이 과정에서 각 램프 존의 전력 수준이 서로 다르게 조정되며, 반경 방향 위치에 따라 서로 다른 전력 분포가 형성된다. 이러한 전력 분포는 다중 열원 간 열 간섭을 고려하여 목표 온도 프로파일을 추종하기 위한 제어 입력의 결과로 해석할 수 있다. Table 4 에 따르면 이 시나리오에서 평균 제곱 오차는 1.19 K^2 , 온도 균일도는 약 1.80 K 수준으로 나타났다.






Fig. 6 Optimized lamp power profiles and wafer temperature responses for representative RTP scenarios (10-zone system). (a) Case 1: Standard spike process, (b) Case 2: Long soak process, (c) Case 3: Soak-to-spike transition process.

4.2.3 Robustness under Fault and Saturation Conditions

액추에이터 결함 및 구동 한계 조건에서 제안된 역설계 방법의 동작 특성을 분석하기 위해 추가적인 실험을 수행하였다. 특히 Case 4-6 은 앞서 Case 3 에서 사용된 동일한 목표 온도 프로파일을 기반으로 하되, 액추에이터 결함 및 포화 조건을 추가하여 시스템의 강건성을 평가하기 위한 시나리오이다. Figure 7 은 이러한 조건에서의 램프 전력 프로파일과 웨이퍼 온도 응답을 보여준다.

Case 4 는 단일 램프 결함 상황을 가정한 시나리오로, Lamp 5 의 출력이 전 구간에서 0 으로 고정된 조건을 고려하였다. Figure 7(a)에서 확인할 수 있듯이 결함이 발생한 램프를 제외한 주변 램프들의 출력이 Case 3 에 비해 상대적으로 증가하는 경향이 나타난다. 이는 동일한 목표 온도 프로파일을 달성하기 위해 결손된 열원을 주변 램프가 보상하는 형태의 전력 재분배로 해석할 수 있다. Table 4 에 따르면 해당 조건에서 평균 제곱 오차는 2.17 K^2 온도 균일도는 약 2.48 K 수준으로 나타났다. Case 5 는 두 개의 램프(Lamp 4 와 Lamp 9)가 동시에 작동하지 않는 이중 결함 시나리오이다. 이 경우 사용 가능한 열원이 더욱 감소하기 때문에 나머지 램프들이 Case 3 및 Case 4 보다 더 높은 출력 수준으로 동작하는 것을 확인할 수 있다. Figure 7(b)의 전력 프로파일에서는 여러 램프가 상한에 가까운 출력 수준에 도달하는 구간이 나타난다. 그럼에도 불구하고 일부 구간에서는 목표 온도 궤적을 충분히 따라가지 못하는 현상이 관찰된다. Table 4 의 결과에서 평균 제곱 오차가 12.15 K^2 로 증가하고 온도 균일도가 약 7.62 K 로 악화되는 것은 이러한 열원 부족 상황에서 시스템의 제어 자유도가 감소한 데 따른 결과로 볼 수 있다.

Case 6 은 시스템의 물리적 가열 및 냉각 능력을 초과하는 고진폭 사인 형태의 목표 온도 궤적을 부여하여 액추에이터 포화 조건에서의 응답을 평가한 시나리오이다. Figure 7(c)의 전력 프로파일에서 확인되듯이 램프 출력이 상한과 하한 사이를 반복적으로 전환하는 구간이 나타난다. 이러한 형태는 목표 온도 궤적을 추종하기 위해 가능한 최대 가열과 냉각을 반복하는 제어 입력 패턴으로 볼 수 있다. 그러나 시스템의 열 용량과 액추에이터 출력 한계로 인해 목표 온도 진폭을 완전히 재현하기는 어려우며, 온도 응답에서는 목표 궤적 대비 진폭이 감소하는 경향이

나타난다. Table 4 에서 평균 제곱 오차가 55.85 K^2 로 증가하는 것은 이러한 구동 한계 조건에서 발생하는 응답 특성을 반영한 결과이다.




Fig. 7 Optimized lamp power profiles and wafer temperature responses under actuator fault and saturation conditions (10-zone system). (a) Case 4: Single lamp fault, (b) Case 5: Double lamp fault, (c) Case 6: Actuator saturation under high-amplitude sinusoidal trajectory.

4.2.4 Comparison with Benchmark Studies

제안된 방법의 제어 성능을 정량적으로 평가하기 위해, 동일한 물리 모델과 동일한 공정 시나리오(Standard Spike)를 사용하여 기존 연구들과의 성능 비교를 수행하였다. 비교 대상은 다중 존 RTP 제어 문제를 다룬 선행 연구인 Jeng & Chen (2013)과 Pradeep & Noel (2018)이며, 각 연구에서 보고된 결과와 동일한 설정을 기준으로 성능을 정리하였다. 비교 결과는 Table 5 에 제시되어 있다.

Table 5 에 나타난 결과는 다중 존 RTP 제어 문제에서 제어 변수 수가 증가할 때 기존 접근법이 겪는 계산 복잡도 증가 현상을 보여준다. 특히 강화학습 기반 접근(Pradeep & Noel, 2018)의 경우 1-zone 에서 약 178.9 초였던 최적화 시간이 3-zone 에서는 약 96,056 초로 크게 증가하였다. 이는 제어 변수 수가 증가함에 따라 탐색 공간이 급격히 확장되는 차원의 저주(Curse of Dimensionality) 현상을 반영한 결과이다.

반면 제안된 DeepONet 기반 접근은 존 수가 증가하더라도 최적화 시간이 약 16.8–16.9 초 수준으로 거의 일정하게 유지되는 것을 확인할 수 있다. 이러한 결과는 학습된 연산자를 이용한 역설계 구조가 제어 변수의 차원 증가에 따른 계산 부담을 크게 완화할 수 있음을 보여준다.

지표별 성능을 살펴보면 기존 방법들은 주로 피크 온도 오차를 최소화하는 데 초점을 두고 있으며, 일부 경우 웨이퍼 전면의 온도 균일성이 상대적으로 크게 악화되는 경향이 나타난다. 예를 들어 강화학습 기반 3-zone 제어에서는 피크 오차가 1.65 K 수준으로 낮게 유지되었으나, 웨이퍼 전면의 온도 편차는 약 4.30 K 수준으로 증가하였다.

반면 제안된 DeepONet 기반 방법은 공간적 온도 균일성을 우선적으로 고려하는 제어 입력을 생성하는 경향을 보였다. Table 5 에서 확인할 수 있듯이 2-zone 및 3-zone 구성에서 각각 약 0.84 K와 0.89 K 수준의 균일도를 유지하였으며, 더 많은 존이 존재하는 10-zone 구성에서도 약 1.16 K 수준의 균일도를 유지하였다. 이러한 결과는 다중 존 RTP 시스템에서 발생하는 반경 방향 열 손실을 고려하여 램프 출력을 분배하는 제어 입력이 형성된 결과로 해석할 수 있다.

전체적으로 볼 때 제안된 방법은 기존 접근법에 비해 계산 시간 측면에서 높은 확장성을 보이며, 동시에 웨이퍼 전면의 온도 균일성을 안정적으로 유지하는 제어 입력을 생성할 수 있음을 확인할 수 있다.

Table 5. Quantitative comparison with benchmark studies under the standard spike RTP scenario

Method	Zone	Computation Time (s)	Peak Error (K)	Uniformity (K)
Jeng & Chen (Nonlinear Wiener Model)	1	-	29.00	5.00
	2	-	28.00	2.00
	3	-	26.00	2.00
Pradeep & Noel (Reinforcement Learning)	1	~178.9	8.50	1.00
	2	~761.8	4.50	1.05
	3	~96,056.6	1.65	4.30
Proposed (DeepONet)	1	~16.9	5.27	1.07
	2	~16.8	5.34	0.84
	3	~16.9	5.38	0.89
	10	~16.9	5.33	1.16

4.2.5 Scalability and Physical Consistency

본 연구의 핵심 목적 중 하나는 다중 존 RTP 시스템에서 제어 변수 수가 증가하더라도 안정적인 역설계 성능을 유지할 수 있는 확장 가능한(*scalable*) 제어 프레임워크를 구축하는 것이다. 제안된 방법은 입력 인코딩 구조를 통해 서로 다른 램프 존 구성을 단일 DeepONet 모델에서 처리하도록 설계되었으며, 별도의 모델 재학습 없이 다양한 존 구성에 적용될 수 있다. 실험 결과에서도 이러한 구조적 특징이 확인되었는데, Table 4 에서 볼 수 있듯이 1-zone 부터 10-zone 까지 존 수가 증가하더라도 웨이퍼 온도 균일도와 피크 온도 오차는 큰 변화 없이 안정적인 수준을 유지하였다. 이는 존 수 증가에 따른 제어 차원의 확대에도 모델이 안정적인 제어 성능을 유지할 수 있음을 의미한다.

또한 제안된 방법은 계산 효율 측면에서도 기존 접근법 대비 높은 확장성을 보였다. Table 5 의 비교 결과에서 확인할 수 있듯이 강화학습 기반 접근(*Pradeep & Noel, 2018*)의 경우 존 수 증가에 따라 계산 시간이 급격히 증가하여 3-zone 환경에서 약 96,056 초의 최적화 시간이 요구되었다. 반면 본 연구에서 제안한 DeepONet 기반 역설계 방법은 1-zone 부터 10-zone 까지 약 16.8–16.9 초 수준의 유사한 계산 시간을 유지하였다. 이러한 결과는 학습된 연산자를 이용한 역설계 구조가 제어 변수 차원 증가에 따른 계산 부담을 크게 완화할 수 있음을 보여준다.

물리적 관점에서도 제안된 모델은 비교적 일관된 제어 거동을 나타냈다. 다중 램프 간 열 간섭이 강하게 나타나는 10-zone 환경에서도 웨이퍼 전면의 온도 균일도가 약 1.16 K 수준으로 유지되었으며, 램프 결함이나 포화 조건과 같은 극한 상황에서도 남은 램프의 출력을 증가시키거나 출력 상한에 근접한 제어 입력을 생성하는 경향이 관찰되었다. 이러한 결과는 모델이 단순히 데이터 패턴을 모방하는 것이 아니라 열 전달 특성과 제어 제약 조건을 반영한 제어 입력을 생성하고 있음을 시사한다.

5 Conclusion

본 연구에서는 다중 존 급속 열처리(*Rapid Thermal Processing, RTP*) 시스템에서의 공정 레시피 설계를 위해 연산자 학습(*Operator Learning*) 기반 역설계 프레임워크를 제안하였다. 제안된 방법은 서로 다른 램프 존 구성을 단일 모델로 처리할 수 있도록 구성 적응형 입력 구조를 도입하여, 다변수 열 공정 제어에서 발생하는 차원의 저주 문제를 완화하는 것을 목표로 한다.

제안된 DeepONet 기반 역설계 구조는 학습된 *forward operator* 를 이용하여 목표 온도 궤적을 만족하는 램프 파워 입력을 직접 최적화하는 방식으로 구성된다. 이를 통해 다중 열원 간 열 간섭이 존재하는 RTP 시스템에서도 웨이퍼 전면 온도 분포를 고려한 공정 레시피 설계가 가능함을 확인하였다. 특히 동일한 모델을 이용하여 1-zone 부터 10-zone 까지 다양한 장비 구성을 처리할 수 있었으며, 이는 장비 구성 변화에 대한 모델 재설계 필요성을 줄일 수 있음을 보여준다.

또한 제안된 접근은 다중 존 제어 문제에서 요구되는 계산 효율 측면에서도 장점을 가진다. 기존 강화학습 기반 접근과 달리 제안된 방법은 제어 변수 수 증가에 따른 계산 시간 증가가 제한적으로 나타났으며, 이는 연산자 학습 기반 역설계 구조가 다변수 열 공정 제어 문제에서 확장 가능한(*scalable*) 제어 전략으로 활용될 가능성을 보여준다.

본 연구의 결과는 연산자 학습 기반 접근이 복잡한 열 공정 시스템에서의 공정 레시피 설계 문제에 적용될 수 있음을 보여준다. 향후 실제 공정 환경에서의 센서 노이즈, 장비 열화, 공정

변동성을 고려한 모델 보정 및 실시간 피드백 제어와의 결합이 이루어진다면, 디지털 트윈 기반 반도체 열 공정 제어 시스템으로 확장될 가능성을 보여준다.

Acknowledgements

Reference

- (1) Lu, L., Jin, P., Pang, G., Zhang, Z. and Karniadakis, G. E., 2021, "Learning Nonlinear Operators via DeepONet Based on the Universal Approximation Theorem of Operators," *Nature Machine Intelligence*, Vol. 3, No. 3, pp. 218–229.
- (2) Koric, S. and Abueidda, D. W., 2023, "Data-Driven and Physics-Informed Deep Learning Operators for Solution of Heat Conduction Equation with Parametric Heat Source," *International Journal of Heat and Mass Transfer*, Vol. 203, Art. No. 123809.
- (3) Shukla, K., Oommen, V., Peyvan, A., Penwarden, M., Plewacki, N., Bravo, L., Ghoshal, A., Kirby, R. M. and Karniadakis, G. E., 2024, "Deep Neural Operators as Accurate Surrogates for Shape Optimization," *Engineering Applications of Artificial Intelligence*, Vol. 129, Art. No. 107615.
- (4) Cheng, Z., Li, Z., Wang, X., Huang, J., Zhang, Z., Hao, Z. and Su, H., 2025, "Accelerating PDE-Constrained Optimization by the Derivative of Neural Operators," *Proc. of the 42nd International Conference on Machine Learning (ICML)*, Vol. 267, pp. 10090–10105.
- (5) Cho, S. W. and Son, H., 2025, "Physics-Informed Deep Inverse Operator Networks for Solving PDE Inverse Problems," *Proc. of the International Conference on Learning Representations (ICLR)*.
- (6) Molinaro, R., Yang, Y., Engquist, B. and Mishra, S., 2023, "Neural Inverse Operators for Solving PDE Inverse Problems," *Proc. of the 40th International Conference on Machine Learning (ICML)*, Vol. 202, pp. 25105–25139.
- (7) Kim, J., Kim, S., Park, J., Seo, S. and So, H., 2025, "Real-Time Monitoring of Temperature Distribution on Silicon Wafer Using Hybrid Neural Network-Based Regression Model," *International Communications in Heat and Mass Transfer*, Vol. 169, Art. No. 109862.
- (8) Goswami, A., Dash, S., Avasthi, S. and Supradeepa, V. R., 2025, "Contactless Temperature Measurement of an In-Process Silicon Wafer Using a Spectrally Shaped Supercontinuum Source," *Optics Express*, Vol. 33, No. 9, pp. 19677–19688.
- (9) Ou, F., Abdullah, F., Wang, H., Tom, M., Orkoulas, G. and Christofides, P. D., 2024, "Sparse Identification Modeling and Predictive Control of Wafer Temperature in an Atomic Layer Etching Reactor," *Chemical Engineering Research and Design*, Vol. 202, pp. 1–11.
- (10) Yu, J., Hanafusa, H. and Higashi, S., 2023, "Development of a Real-Time Temperature Measurement Technique for SiC Wafer During Ultra-Rapid Thermal Annealing Based on Optical-Interference Contactless Thermometry," *Japanese Journal of Applied Physics*, Vol. 62, Art. No. SC1075.

- (11) Hayashi, D., Takijiri, K. and Ueda, T., 2023, "Wafer Temperature Control Using Helium Pressure and Observer-Based Model Predictive Control," *ASME Letters in Dynamic Systems and Control*, Vol. 3, No. 3, Art. No. 031001.
- (12) Koch, S., Schaum, A., Kleindienst, M., Reichhartinger, M., Meurer, T., Moreno, J. A. and Horn, M., 2022, "Model-Based Temperature Control in Thermal Processing of Silicon Wafers," *IFAC-PapersOnLine*, Vol. 55, No. 26, pp. 180–186.
- (13) Schaum, A., Koch, S., Kleindienst, M., Reichhartinger, M., Meurer, T., Moreno, J. A. and Horn, M., 2022, "Observer Design for a Nonlinear Heat Equation: Application to Semiconductor Wafer Processing," *Journal of Process Control*, Vol. 119, pp. 34–43.
- (14) Tranninger, M., Seeber, R., Steinberger, M. and Horn, M., 2020, "Efficient Temperature Profile Estimation for Silicon Wafers Based on Subspace Observers," *IFAC-PapersOnLine*, Vol. 53, No. 2, pp. 5952–5957.
- (15) Kleindienst, M., Reichhartinger, M., Koch, S. and Horn, M., 2019, "A Distributed-Parameter Approach for the Surface Temperature Estimation of an LED Heated Silicon Wafer," *IEEE Transactions on Semiconductor Manufacturing*, Vol. 32, No. 4, pp. 559–565.
- (16) Xiao, T. and Li, H. X., 2019, "Dominant-Modes-Based Sliding-Mode Observer for Estimation of Temperature Distribution in Rapid Thermal Processing System," *IEEE Transactions on Industrial Informatics*, Vol. 15, No. 5, pp. 2673–2681.
- (17) Pradeep, D. J. and Noel, M. M., 2018, "A Finite Horizon Markov Decision Process Based Reinforcement Learning Control of a Rapid Thermal Processing System," *Journal of Process Control*, Vol. 68, pp. 218–225.
- (18) Kleindienst, M., Reichhartinger, M., Horn, M. and Staudegger, F., 2018, "Observer-Based Temperature Control of an LED Heated Silicon Wafer," *Journal of Process Control*, Vol. 70, pp. 96–108.
- (19) Trudgen, M. and Velni, J. M., 2018, "Linear Parameter-Varying Approach for Modeling and Control of Rapid Thermal Processes," *International Journal of Control, Automation and Systems*, Vol. 16, No. 1, pp. 207–216.
- (20) Won, W., Park, K. and Kim, J., 2017, "Combined Iterative Learning and Delta-Operator Adaptive Linear Quadratic Gaussian Control of a Commercial Rapid Thermal Processing System," *Chemical Engineering Science*, Vol. 174, pp. 146–156.
- (21) Xiao, T. and Li, H. X., 2016, "Sliding Mode Control Design for a Rapid Thermal Processing System," *Chemical Engineering Science*, Vol. 143, pp. 76–85.
- (22) Jeng, J. C. and Chen, W. C., 2013, "Control Strategies for Thermal Budget and Temperature Uniformity in Spike Rapid Thermal Processing Systems," *Computers and Chemical Engineering*, Vol. 57, pp. 141–150.
- (23) Cho, W., Edgar, T. F. and Lee, J., 2008, "Nonlinear Model Identification for Temperature Control in Single Wafer Rapid Thermal Processing," *Industrial & Engineering Chemistry Research*, Vol. 47, No. 14, pp. 4791–4796.
- (24) Dassau, E., Grosman, B. and Lewin, D. R., 2006, "Modeling and Temperature Control of Rapid Thermal Processing," *Computers & Chemical Engineering*, Vol. 30, No. 4, pp. 686–697.

- (25) Cho, M., Lee, Y., Joo, S. and Lee, K. S., 2005, "Semi-Empirical Model-Based Multivariable Iterative Learning Control of an RTP System," IEEE Transactions on Semiconductor Manufacturing, Vol. 18, No. 3, pp. 430–439.
- (26) Yang, D. R., Lee, K. S., Ahn, H. J. and Lee, J. H., 2003, "Experimental Application of a Quadratic Optimal Iterative Learning Control Method for Control of Wafer Temperature Uniformity in Rapid Thermal Processing," IEEE Transactions on Semiconductor Manufacturing, Vol. 16, No. 1, pp. 36–44.
- (27) Emami-Naeini, A., Ebert, J. L., de Roover, D., Kosut, R. L., Dettori, M., Porter, L. M. and Ghosal, S., 2003, "Modeling and Control of Distributed Thermal Systems," IEEE Transactions on Control Systems Technology, Vol. 11, No. 5, pp. 668–683.
- (28) Choi, J. Y. and Do, H. M., 2001, "A Learning Approach of Wafer Temperature Control in a Rapid Thermal Processing System," IEEE Transactions on Semiconductor Manufacturing, Vol. 14, No. 1, pp. 1–10.
- (29) Lee, K. S., Lee, J., Chin, I., Choi, J. and Lee, J. H., 2001, "Control of Wafer Temperature Uniformity in Rapid Thermal Processing Using an Optimal Iterative Learning Control Technique," Industrial & Engineering Chemistry Research, Vol. 40, No. 7, pp. 1661–1672.
- (30) Edgar, T. F., Butler, S. W., Campbell, W. J., Pfeiffer, C., Bode, C., Hwang, S. B., Balakrishnan, K. S. and Hahn, J., 2000, "Automatic Control in Microelectronics Manufacturing: Practices, Challenges, and Possibilities," Automatica, Vol. 36, No. 11, pp. 1567–1603.
- (31) Balakrishnan, K. and Edgar, T. F., 2000, "Model-Based Control in Rapid Thermal Processing," Thin Solid Films, Vol. 365, No. 2, pp. 322–333.
- (32) Huang, C. J., Yu, C. C. and Shen, S. H., 2000, "Selection of Measurement Locations for the Control of Rapid Thermal Processor," Automatica, Vol. 36, No. 5, pp. 705–715.
- (33) Schaper, C. D. and Kailath, T., 1999, "Decentralized Control of Wafer Temperature for Multizone Rapid Thermal Processing Systems," IEEE Transactions on Semiconductor Manufacturing, Vol. 12, No. 2, pp. 193–199.
- (34) Schaper, C. D., Moslehi, M. M., Saraswat, K. C. and Kailath, T., 1994, "Modeling, Identification, and Control of Rapid Thermal Processing Systems," Journal of the Electrochemical Society, Vol. 141, No. 11, pp. 3200–3209.