

2025 데이터 크리에이터 캠프

DATA
CREATOR
CAMP

대학부 팀명 : JBIG 4.0





Contents

목차

01

Mission 3

산업단지 영역 분할 (Semantic Segmentation)

02

Mission 4-1

다중모달 융합 (Multimodal Fusion)

03

Mission 4-2

전이학습 (Transfer Learning)

04

최종 결과

앙상블 (Ensemble)




01 Mission 3

산업단지 영역 분할 (Semantic Segmentation)




MISSION 3

데이터 품질 분석 및 전처리 근거



결측값이 거의 0%에 가까워
센서 이상·데이터 손실이 거의 없음



Coverage가 0.7~0.9에 집중
→ 클래스 불균형 없음

평균 결측비율 0.005%, Coverage 0.825 ± 0.114
→ 데이터 품질 양호



MISSION 3

원본 위성영상과 산업단지 마스크 비교 시각화

원본 위성 2×2 샘플



실제 Sentinel-2 RGB 원본
(밝기·지형 다양성 확인)

마스크 오버레이 2×2 샘플



산업단지 마스크 오버레이
(녹색 부분이 산업단지)

산업단지 경계가 명확히 식별되며, 도시/농경지 구분이 선명

→ 피쳐 분리가 잘 이루어졌음을 시각적으로 증명



MISSION 3

모델 구조 세부 비교

1. UNet++ : 지역 정밀도 강화형

- UNet++은 미세 구조 복원력(경계 표현)에 강점
- EfficientNet-B5 encoder → 밴드별 스케일 차이 보정
- Dense skip connection → 미세 경계 복원력 강화
- 5채널 입력 (4밴드 + 결측마스크) 구조 적용



2. DeepLabV3+ : 전역 문맥 인식형

- DeepLabV3+는 넓은 영역 분할(매끄러운 경계)에 강점
- ASPP 모듈로 전역 문맥 인식 향상 → 넓은 receptive field 확보
- EfficientNet-B5 backbone → 대면적 패턴 탐지에 유리
- 5채널 입력 유지 → 결측 영역 정보 학습 가능





MISSION 3

Train / Validation 루프 & 손실함수(Loss Function)

Train→Validate→Scheduler의 표준 루프를 통해 손실과 지표를 동시에 추적

- Train 단계: BCE+Dice 손실 기반 역전파 수행
- Validate 단계: mIoU 계산으로 성능 모니터링
- CosineAnnealing으로 학습률 점진 감소

BCE + Dice 병합 손실로 클래스 불균형을 완화하고 경계 복원력을 강화

- 손실함수를 통해서 모델의 예측값과 실제값 사이의 오차를 측정하고, 이 오차를 최소화하여 모델의 성능을 개선
- DiceLoss: 예측-정답 겹침률(Dice) 극대화 → 경계·미세 구조 학습 강화
- BCE w/ logits: 안정적 시그모이드 + 로짓 기반 → 전역 픽셀 정확도 보완
- 가중 결합($\alpha=0.5$): 불균형 데이터에서 안정적 수렴과 균형 학습
- 학습 루프(AMP 포함)에서 이 bce_dice_loss를 직접 사용



MISSION 3

5채널 : MissingMask 결합 & 품질 필터링

RGB+NIR 4밴드에 결측 위치 마스크를 추가해 결측 영역을 인식하는 강건한 입력 구성

- 채널별 median으로 결측값 보간
- 결측 여부를 NaN·비유효값 기준으로 계산하여 MissingMask(0/1) 생성
- 최종 입력: [4밴드 + 1마스크] = 5채널 구조
- 모델이 결측 영역 자체의 패턴을 학습할 수 있도록 설계

결측률이 높은 이미지(30% 초과)를 사전 제거해 노이즈를 줄이고 학습 안정성 확보

- 결측률 30% 초과 샘플 제외 → 데이터 왜곡 및 노이즈 최소화
- 중심·모서리 패치 3곳 샘플링으로 결측 비율 추정
- 기준 이하만 유지하여 깨끗한 데이터셋 확보
- 학습 전 필터링으로 정규화 통계의 신뢰도 향상



MISSION 3

파인튜닝 학습 : Optimizer & Scheduler

AdamW + CosineAnnealingLR로 일반화와 안정 수렴을 동시에 확보

- AdamW: weight_decay로 과적합 억제 및 일반화 강화
- CosineAnnealingLR: 학습 후반 안정적 수렴
- T_max=epochs → 전체 에폭 단위로 학습률 조정

AMP로 연산 효율을 높이고 VRAM 사용량을 절감

- autocast: FP16/FP32 자동 전환 → 연산량 감소
- GradScaler: FP16 언더플로 방지 → 수치 안정성 확보
- EffNet-B5 + 512 해상도 환경에서도 안정적 학습 가능
- 학습 속도 ↑, 메모리 사용량 ↓



02

Mission 4-1

다중모달 융합 (Multimodal Fusion)



MISSION 4-1

고·저해상도 위성 데이터의 공간 정합 및 멀티모달 융합

Sentinel-2 (고해상도)와 GE
MS/AIR (저해상도)의 경로
매칭 후 분리



GEMS/AIR 데이터를 확대
→공간적 불일치 문제 해결



Sentinel-2 5채널
+
GEMS/AIR N채널




늘어난 채널 수에 맞게
모델 구조를 조정




성능 최적화
(4-View TTA를 적용)


A. Sentinel-2 Original (512x512)
(High-Resolution)



B. GEMS/AIR (Nearest Upsample)
Size: 64x64 -> 512x512



C. GEMS/AIR (Linear Interpolation)
(Used for Channel Fusion)



	미션 3	미션 4-1 (멀티모달 융합)
채널 구성	5채널 (RGB + NIR + Mask)	5 + N 채널 (RGB + NIR + Mask + GEMS/AIR)



03

Mission 4-2

전이학습 (Transfer Learning)



MISSION 4-2

LS30 Pretrain (Robust Feature Learning)

- 고해상도 LS30 (0 ~ 65535 범위)의 넓은 정보량을 활용해 강력한 저·중간 수준 Feature Extractor를 먼저 구축

1) 센서 전용 Valid Range

- LS30만의 범위 (0 ~ 65535)를 적용해 실제 유효 신호와 결측치 (NaN)를 명확하게 분리
- 모든 전처리 + missing-mask 생성이 LS30 전용 기준으로 진행됨

2) 결측률 필터링

- Missing 비율이 80%를 초과하는 tif는 제거
- 구름·흐림·밴드오류가 많은 LS30에서 데이터 품질을 보장

3) 강한 데이터 증강

- LS30 pretrain은 이미지 강화가 목적이므로 SN10보다 더 강한 augmentation 적용 :
RandomResizedCrop / Horizontal, Vertical Flip / RandomRotate90 / Noise / CoarseDropout

4) 5채널 입력 구조


- 센서 특징을 더 정교하게 학습하도록 결측 위치 정보를 담은 missing - mask 채널 포함
- raw 4ch는 valid-range 기반 0~1 표준화





MISSION 4-2

Flow Chart





04

최종 결과

앙상블 (Ensemble)



최종 결과

모델 성능 비교

구조	입력 채널	특징	mIoU
U-Net++ (EffNet-B5) & DeepLabV3+	5채널	MISSION 3	98.41
U-Net++ (EffNet-B5)	멀티모달(6ch)	skip connection이 풍부한 구조, 경계 복원 강점	98.79
DeepLabV3+ (EffNet-B5)	멀티모달(6ch)	ASPP로 넓은 문맥 정보, 큰 패턴 강점	98.76
DeepLabV3+	SN10 fine-tuning (5→6ch 변환)	SN10 데이터에 특화된 특성	98.72



최종 결과

앙상블 전략

TTA + Logit 평균


- 각 모델에 대해 TTA(Test Time Augmentation):
원본, 좌우 플립, 상하 플립, 둘 다 플립 → 4개 prediction
4개의 logit을 평균 → 모델별 최종 logit 생성
- 여러 모델 앙상블:
모델별 logit을 다시 평균
soft voting(확률/로짓 기반 평균)이라,
한 모델이 과하게 틀린 부분을 다른 모델이 완화

$$\hat{y} = \sigma \left(\frac{1}{K} \sum_{k=1}^K \text{logit}_k \right)$$



최종 결과

최종 성능 비교





본콘텐츠는 한국지능정보사회진흥원(NIA)의 동의없이 무단 사용할 수 없으며
상업적 목적으로 이용을 금합니다.

2025 데이터 크리에이터 캠프

감사합니다

